

Revu de TP
SGBD

-

Systèmes de Gestion de Bases de Données

-

RIGLET Flavien et LARDI Nicolas

November 2019

Plan

1	Introduction	3
2	Initialisation	4
2.1	Précision :	4
3	Série de test	5
3.1	Test 1	5
3.1.1	Ce que l'on cherche	5
3.1.2	Conditions de l'expérience	5
3.1.3	Les requêtes SQL	6
3.1.4	Résultats des tests	7
3.1.5	Interprétation des résultats :	7
3.2	Test 2	8
3.2.1	Ce que l'on cherche :	8
3.2.2	Condition de l'expérience	8
3.2.3	Résultats des tests	8
3.2.4	Interprétation des résultats	8
3.3	Test 3 : Comparatif des recherches de tuples sur des intervalles de valeurs différents, les unes à travers un index primaire et les autres à travers un index secondaire.	9
3.3.1	Ce que l'on cherche	9
3.3.2	Les requêtes SQL	9
3.3.3	Résultats des tests	10
3.3.4	Interprétation des résultats	10
3.4	Test 4 : Comparatif des recherches de tuples à travers un index secondaire et les même recherches dans une table stockée dans un cluster de type "hash-code".	11
3.4.1	Ce que l'on cherche :	11
3.4.2	Les requêtes SQL	11
3.4.3	Résultats des tests	12
3.4.4	Interprétation des résultats	12
3.5	Test 5 : Comparatif de la taille des index secondaires et bitmap.	13
3.5.1	Ce que l'on cherche	13
3.5.2	Les requêtes SQL	13
3.5.3	Résultats des tests	14
3.5.4	Interprétation des résultats	14
3.6	Test 6 : Étude de l'impact de la clause PC_TFREE lors de la création d'une table ou d'un index.	15
3.6.1	Ce que l'on cherche	15

3.6.2	Les requêtes SQL	15
3.6.3	Résultats des tests & Interprétation	15
3.7	Test 7 : Étude des plans d'exécution de requêtes multi-critères en présence d'un ou plusieurs indexes, secondaires ou bitmap.	16
3.7.1	Ce que l'on cherche	16
3.7.2	Condition de l'expérience	16
3.7.3	Les requêtes SQL	16
3.7.4	Résultats des tests	17
3.7.5	Interprétation des résultats	18
3.8	Test 8 : Identification des situations dans lesquelles chaque type d'algorithme de jointure est utilisé.	19
3.8.1	Ce que l'on cherche	19
3.8.2	Les requêtes SQL & Résultats des tests	19
3.8.3	Interprétation des résultats	21
4	Conclusion	21
	Annexe	22
A	Construction des tables	22
B	Mesures	24
C	Plans d'exécution du test 7	25

Partie 1

Introduction

Dans le but de mieux comprendre Oracle nous allons réaliser plusieurs tests ayant pour but d'analyser l'utilité des primitives offertes par Oracle. Chaque test est indépendant et nous donnerons des résultats que nous exploiterons afin d'avoir une interprétation logique et une conclusion sur les points fort et les points faible de chaque primitives.

En plus d'effectuer ces tests, nous apprendrons de nouvelles méthodes en plus d'appliquer celle que nous avons déjà pu rencontrer lors de nos cours. On utilisera dans un premiers temps les notion de clé primaire et d'index secondaire. Puis nous mettrons en pratique les cluster de type "hash-code", les requêtes multi-critères AND et OR pour finir sur les différents algorithmes de jointure (produit cartésien, sort-merge, key-lookup, hash-code).

Nous visualiserons, de plus, le nombre de blocs effectivement utilisés, l'impact du PCTFREE lors de la création et de l'exploitation de nos table ou d'un index, les segments et les différents plans d'exécution de nos requêtes.

Chaque test sera détaillées en plusieurs points. Tout d'abord nous écrirons en quoi consiste le test que nous traiterons, en second nous donnerons les conditions de l'expérience avec notre plan d'analyse, puis les requêtes que nous avons utilisés pour finir sur les résultats que nous avons obtenus et l'interprétation que nous en avons fait.



Partie 2

Initialisation

2.1 Précision :

Avant de débiter, nous avons utilisé les commandes suivantes:

```
1 SET AUTOTRACE ON;  
2 SET SERVER OUTPUT ON SIZE 3000;
```

dans Oracle pour pouvoir visualiser les différents messages émis dans la console par le serveur.

Autre commande utilisée :

```
1 EXEC DBMS_STATS.GATHER_SCHEMA_STATS( 'fr108211 ', cascade=>TRUE);  
2 ALTER SYSTEM FLUSH BUFFER_CACHE;  
3 ALTER SYSTEM FLUSH SHARED_POOL;
```

Ces commandes permettent de vider les buffers ainsi que de remettre à zéro les statistiques d'optimisation des requêtes afin que l'exécution de nos tests ne faussent pas les résultats des requêtes suivantes. On lancera ces trois commandes avant chaque requête pour être certain qu'ORACLE fonctionne "par défaut".

Pour la création des nos tables, nous avons utilisé les fonctions PL/SQL vues en TP, permettant de créer nos tables et de les remplir selon certains critères.

Nous modélisons une base de données représentant des étudiants et étant composée de différentes relations. Nous nous intéresseront à la table principale "*Etudiant*", les autres servant simplement à construire cette même table. Les fonctions de génération sont disponibles en annexe.

Attention, la plupart des graphes et schémas présentés dans ce rapport disposent d'échelles non linéaires.

Partie 3

Série de test

3.1 Test 1

3.1.1 Ce que l'on cherche

On cherche à connaître le seuil d'utilisation des indexes secondaires en fonction de la proportion de tuples recherchés.

3.1.2 Conditions de l'expérience

Dans un premier temps nous créons une table Étudiant ayant comme condition de remplissage un pourcentage d'étudiant dans chaque ville qui est paramétré à l'avance. Nous paramétrons le pourcentage de ville comme suit :

Paris	1%
Lyon	3%
Dijon	4%
Chalon	5%
Longvic	6%
Quetigny	7%
Chenove	10%
Chevigny	23%
Bressey	39%

Cette répartition nous permettra d'évaluer où se trouve le seuil d'utilisation des indexes avec une précision de moins de 1% pour les villes allant de Paris à Quetigny.

3.1.3 Les requêtes SQL

```

1 CREATE OR REPLACE PROCEDURE CHRONO AS
2   hd timestamp;
3   hf timestamp;
4   duree interval day to second;
5   v_nb number(6);
6
7 BEGIN
8   hd:=systimestamp;
9   SELECT /*+ INDEX(Etudiant_1 IVille_1) */ count(*) INTO v_nb FROM ETUDIANT_1
10      WHERE villeEtu = 'Bressey' AND descriptif LIKE '%';
11   hf:= systimestamp;
12   duree :=hf-hd;
13   DBMS_OUTPUT.PUT_LINE('Requete SQL: '||EXTRACT(minute FROM duree)||
14      ' minutes '|| EXTRACT(second FROM duree)|| ' seconds');
15 end;
16 ./
17 EXEC DBMS_STATS.GATHER_SCHEMA_STATS('fr108211', CASCADE=>TRUE);
18 ALTER SYSTEM FLUSH BUFFER_CACHE;
19 ALTER SYSTEM FLUSH SHARED_POOL;
20 BEGIN
21     CHRONO;
22 END;/

```

Figure 3.1: Procédure CHRONO et lancement automatique.
Permet de chronométrer le temps d'exécution d'une requête

```

1 EXEC DBMS_STATS.GATHER_SCHEMA_STATS('fr108211', CASCADE=>TRUE);
2 ALTER SYSTEM FLUSH BUFFER_CACHE;
3 ALTER SYSTEM FLUSH SHARED_POOL;
4 SELECT count(*)
5 FROM ETUDIANT_1 WHERE villeEtu = 'Lyon'
6 AND descriptif LIKE '%';

```

Figure 3.2: Requête permettant d'accéder aux étudiants d'une ville

3.1.4 Résultats des tests

Seuil d'utilisation des indexes

Après avoir utilisé la commande 3.2 pour chaque ville, on remarque que ORACLE cesse d'utiliser l'index secondaire quand la proportion des tuples recherchés dans la table excède 3%.

Seuil optimal

Afin de trouver le seuil optimal (seuil auquel l'utilisation de l'index est le même que le balayage séquentiel), on utilise la procédure CHRONO 3.1 avec un HINT permettant de forcer l'utilisation de l'index ou du balayage séquentiel. Pour chaque ville, on fait la moyenne du temps d'exécution de 5 requêtes identiques successives en forçant l'index puis le balayage. Les résultats sont renseignés dans le tableau ci-dessous.

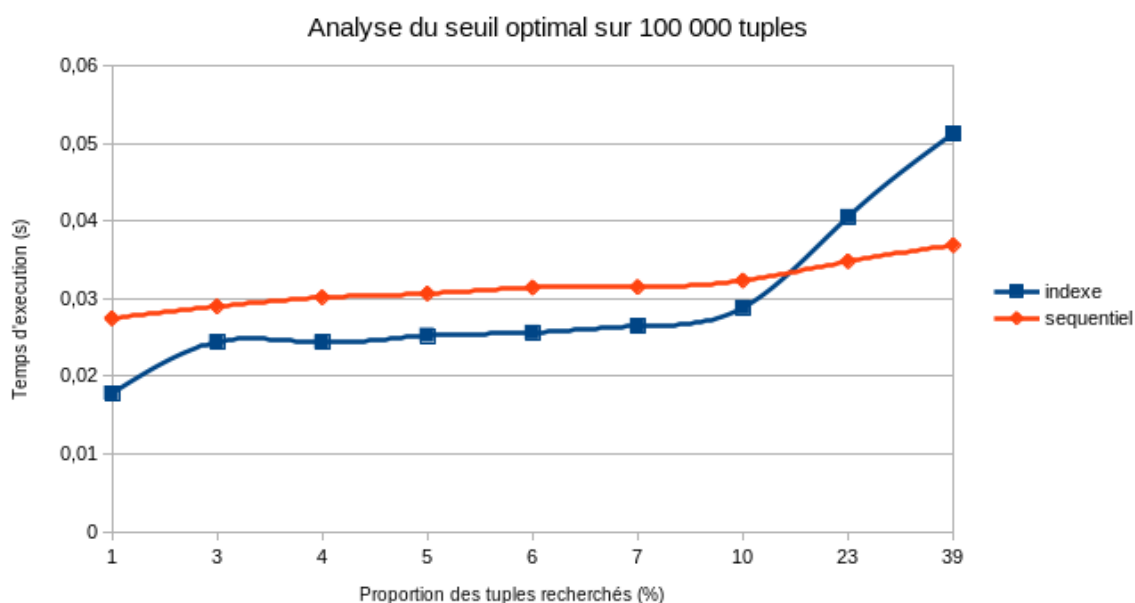


Figure 3.3: Évolution du temps d'exécution des requêtes en fonction du plan d'exécution et de la proportion des tuples recherchés

3.1.5 Interprétation des résultats :

On remarque que le seuil optimal trouvé est d'environ 14% ce qui montre une différence assez élevée avec le seuil utilisé par ORACLE. Nous pensons qu'à notre échelle, c'est à dire avec une base de données de faible taille et surtout avec des requêtes de l'ordre du centième de seconde, ORACLE ne fait pas forcément le choix le plus optimal mais il choisit un plan d'exécution raisonnable en temps. Autrement dit il ne choisit pas le meilleur raisonnement mais évite les plus mauvais.

3.2 Test 2

3.2.1 Ce que l'on cherche :

Étude de la variation du seuil optimal et du passage de l'indexe à l'utilisation du balayage séquentiel en fonction de la taille des tuples

3.2.2 Condition de l'expérience

Nous allons modifier la taille du champ *"description"* de nos étudiants et comparer les variations des seuils d'utilisation des indexes secondaires si ils existent. Le test présenté en 3.3, page 7 disposait de tuples ayant tous pour *"description"* une chaîne de caractère de taille 25. On fera varier la taille de ce champ à 500 puis à 2000. Les requêtes utilisées sont les mêmes que pour la question 1, on aura juste créé une autre table avec des tuples d'une taille différente.

3.2.3 Résultats des tests


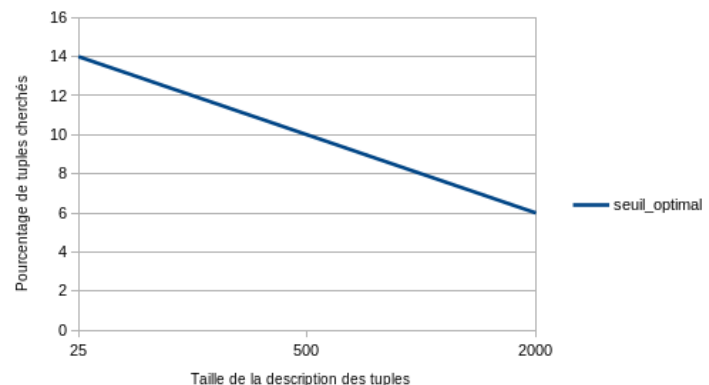


Figure 3.4: Évolution du temps d'exécution des requêtes en fonction du plan d'exécution et de la proportion des tuples recherchés. Taille de 500 à gauche et 2000 à droite.

3.2.4 Interprétation des résultats

Nous pouvons remarquer que le seuil optimal diminue grandement en fonction de la taille de nos tuples. Donc plus nos tuples sont grands, plus l'utilisation du balayage séquentiel au profit de l'utilisation de l'indexe se fera tôt. Les courbes se rejoignent car la table peut être chargée en mémoire entièrement compte tenu de sa taille relativement acceptable, le balayage séquentiel et l'utilisation de l'indexe deviennent équivalents.



3.3 Test 3 : Comparatif des recherches de tuples sur des intervalles de valeurs différents, les unes à travers un index primaire et les autres à travers un index secondaire.

3.3.1 Ce que l'on cherche

On cherche à mettre en évidence l'utilité d'un index primaire par rapport à un index secondaire dans des requêtes de sélections portant sur un attribut indexé. On différenciera l'utilisation des indexes ainsi que la "dispersion" des tuples recherchés dans la table

3.3.2 Les requêtes SQL

Pour créer l'index *primaire*, on construit la table comme suit:

```

1 CREATE TABLE Etudiant_2 (
2     noEtu NUMBER(6,0),
3     nomEtu VARCHAR(50),
4     villeEtu VARCHAR(30),
5     statut_Marital CHAR(1),
6     genre CHAR(1),
7     descriptif VARCHAR(2000),
8     CONSTRAINT pk_noetu PRIMARY KEY (NoEtu),
9     FOREIGN KEY (statut_Marital) REFERENCES Stat_Marital (Statut_Marital),
10    FOREIGN KEY (villeEtu) REFERENCES Ville_2 (nomVille),
11    FOREIGN KEY (genre) REFERENCES Genre (type_genre)
12 ) ORGANIZATION INDEX;
```

On construit la table avec un index *secondaire* comme suit:

```

1 CREATE TABLE Etudiant_2 (
2     noEtu NUMBER(6,0),
3     nomEtu VARCHAR(50),
4     villeEtu VARCHAR(30),
5     statut_Marital CHAR(1),
6     genre CHAR(1),
7     descriptif VARCHAR(2000),
8     FOREIGN KEY (statut_Marital) REFERENCES Stat_Marital (Statut_Marital),
9     FOREIGN KEY (villeEtu) REFERENCES Ville_2 (nomVille),
10    FOREIGN KEY (genre) REFERENCES Genre (type_genre)
11 );
12 CREATE INDEX Ino ON Etudiant_2 (noEtu);
```

Requêtes utilisées avec l'index *primaire*:

```
1 SELECT COUNT(*) FROM ETUDIANT WHERE nEtu <= 10000 AND descriptif like '%';
2 SELECT COUNT(*) FROM ETUDIANT WHERE MOD(nEtu,10)=0 AND descriptif like '%';
```

Requêtes utilisées avec l'index *secondaire*; On utilise *ORDER BY DBMS_RANDOM.VALUE* pour ne pas utiliser la table dans l'ordre trié en fonction de noEtu, notre table étant remplie avec des numéros d'étudiants croissants.

```
1 SELECT COUNT(*) FROM ETUDIANT WHERE nEtu <= 10000 AND descriptif like '%';
2 ORDER BY DBMS_RANDOM.VALUE;
3 SELECT COUNT(*) FROM ETUDIANT WHERE MOD(nEtu,10)= 0 AND descriptif like '%';
4 ORDER BY DBMS_RANDOM.VALUE;
```

3.3.3 Résultats des tests

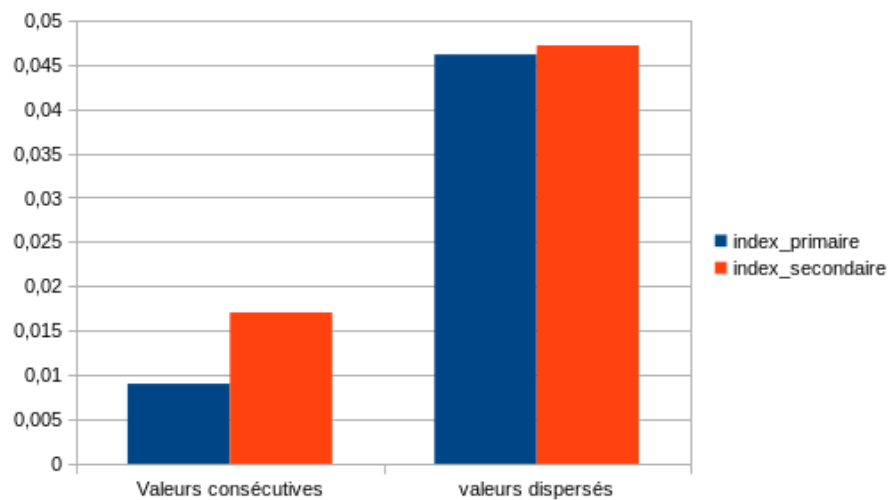


Figure 3.5: Différence entre les recherches des tuples consécutifs ou dispersés

3.3.4 Interprétation des résultats

Nous pouvons constater que la recherche de tuples consécutifs est bien plus rentable en terme de temps de recherche plutôt que la recherche de tuples dispersés. Nous pouvons de plus remarquer une différence de temps de recherche de facteur 5 pour le passage des valeurs consécutives aux valeurs dispersés pour l'index primaire et une différence d'un facteur 3 pour le passage des valeurs consécutives aux valeurs dispersés pour l'index secondaire.

3.4 Test 4 : Comparatif des recherches de tuples à travers un index secondaire et les même recherches dans une table stockée dans un cluster de type "hash-code".

3.4.1 Ce que l'on cherche :

Le cluster est une organisation physique des données qui consiste à regrouper physiquement (dans des bloc consecutifs sur le disque) les lignes d'une ou plusieurs tables ayant une caractéristique commune (une même valeur dans une ou plusieurs colonnes) constituant la clé du cluster. La valeur de la clé de hash code limite le nombre de clés différentes. Mettre un attribut d'une table dans un cluster a plusieurs objectifs:

- Accélérer la jointure selon la clé de cluster des tables mises en cluster,
- Accélérer la sélection des lignes d'une table ayant même valeur de clé, par le fait que ces lignes sont regroupées physiquement
- Économiser de la place, du fait que chaque valeur de la clé du cluster ne sera stockée qu'une seule fois.

Nous allons donc comparer la recherche de tuples à travers un index secondaire et faire de même avec une table de même taille stockée dans un cluster de type "hash-code".

3.4.2 Les requêtes SQL

Création du cluster:

```

1 DROP CLUSTER Clu_etu INCLUDING TABLES;
2 CREATE CLUSTER Clu_etu ( villeetu VARCHAR(30))
3 HASHKEYS 10 ;
4
5 CREATE TABLE ETUDIANT_CLU
6 CLUSTER Clu_etu( villeetu )
7 AS SELECT * FROM ETUDIANT_2;
```

On utilise notre procédure CHRONO avec un HINT permettant de forcer le cluster:

```

1 SELECT /*+ CLUSTER(clu_etu)*/ count(*)
   FROM Etudiant_clu WHERE villeEtu = 'Bressey';
```

Plan d'exécution:

	Id	Operation	Name	Rows	Bytes	Cost(\%CPU)	Time
	0	SELECT STATEMENT		1	9	1 (0)	00:00:01
	1	SORT AGGREGATE		1	9		
*	2	TABLE ACCESS HASH	ETUDIANT_CLU	38545	338K	1 (0)	00:00:01

3.4.3 Résultats des tests

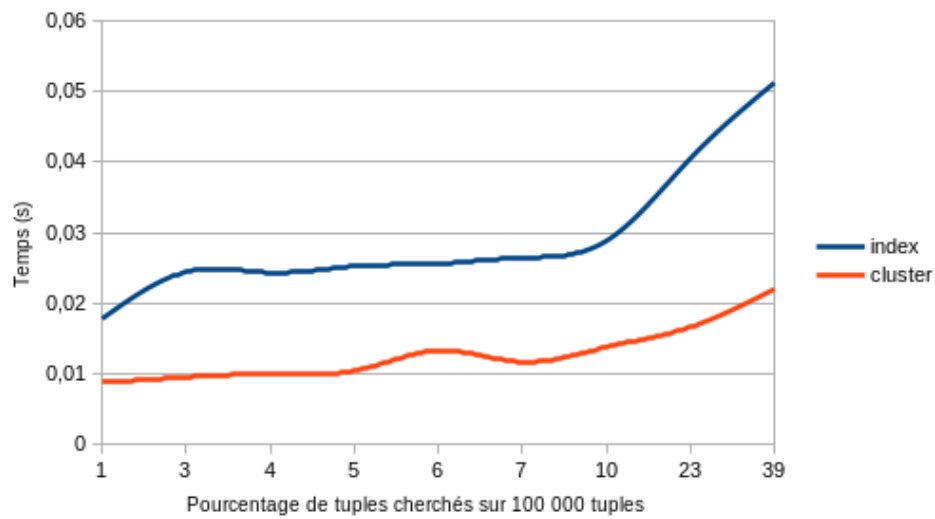


Figure 3.6: Évolution du temps d'exécution des requêtes en fonction du plan d'exécution (index ou cluster) et de la proportion des tuples recherchés.

3.4.4 Interprétation des résultats

On remarque que l'utilisation du cluster est constamment plus rapide. En effet, l'index secondaire possède des pointeurs sur la table entière, alors que le cluster permet de n'exploiter que les tuples en relation avec la requête (si elle porte sur les attributs pointés) ce qui lui permet de gagner un temps non négligeable. Le cluster n'a besoin d'entreprendre que deux lectures pour accéder au bucket contenant les tuples désirés, un pour trouver la clé dans l'index du cluster, et un pour accéder aux tuples pointés par ce premier index.

3.5 Test 5 : Comparatif de la taille des index secondaires et bitmap.

3.5.1 Ce que l'on cherche

Les index Bitmap sont destinés à l'indexation de colonnes qui comportent peu de valeurs distinctes et beaucoup d'enregistrements pour chacune de ces valeurs.

A l'inverse des index B-Tree, les index Bitmap ne stockent pas un pointeur vers un enregistrement dans un fichier trié sur l'index, mais une valeur codée sur un bit (vrai ou faux) pour chaque valeur de la colonne indexée dans un fichier trié sur la clé.

De tels index optimisent les recherches de sélection puisque il suffit d'analyser un bit plutôt que de comparer des chaînes.

On veut ici comparer la taille en nombre de bloc prise en mémoire de différents index sur différents attributs. On va donc comparer le nombres de blocs occupés en mémoire par un index bitmap sur différents attributs de la table étudiant_2 ayant 100 000 tuples.

3.5.2 Les requêtes SQL

On recherche la taille des blocs paramétrée dans le serveur:

```
1 SELECT DISTINCT bytes/blocks FROM USER_SEGMENTS;  
2  
3 BYTES/BLOCKS  
4  
5      8192
```

On crée ensuite les indexes plusieurs fois sur les différents attributs de nos étudiants pour comparer le coût des indexes:

```
1 CREATE INDEX iVille ON ETUDIANT_2(<ATTRIBUT>);  
2 CREATE BITMAP INDEX BIT_VILLE ON ETUDIANT_2 (<ATTRIBUT>);  
3 SELECT BLOCKS FROM USER_SEGMENTS WHERE SEGMENT_NAME = 'iVILLE';
```

3.5.3 Résultats des tests

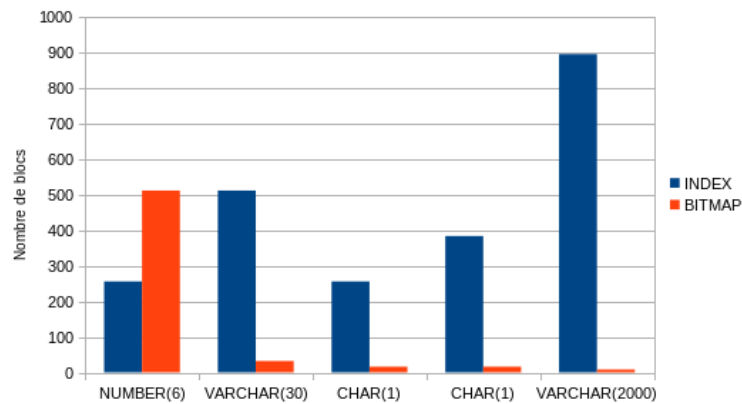


Figure 3.7: Taille des indexes bitmap

On distingue ici les 5 différents attributs de nos étudiants:

- Number(6) : Identifiant -> Numéro d'étudiant.
- Varchar(30) : Ville
- Char(1) : Genre
- Char(1) : Statut marital
- Varchar(2000) : Descriptif

On note que nous n'avons pas testé le nom de nos étudiants compte tenu que nous les avons tous nommé 'Bob'. Le résultat aurait été le même que pour le descriptif qui est lui aussi le même pour tous les tuples.

3.5.4 Interprétation des résultats

On peut conclure que les indexes bitmap sont intéressants en terme de taille quand ils indexent des attributs dont les valeurs possibles sont limitées, comme on peut le voir pour le descriptif qui ne dispose que d'une valeur distincte sur toute la table; Cet index n'ayant qu'une taille de 8 blocs, par rapport à celui du numéro d'étudiant unique pour chaque tuple, pesant 512 blocs.

3.6 Test 6 : Étude de l'impact de la clause PCT_FREE lors de la création d'une table ou d'un index.

3.6.1 Ce que l'on cherche

Ce test consiste à observer l'impact de la clause PCT_FREE sur nos tables et à observer les mécaniques mises en place quand on dépasse le seuil prévu par cette clause.

3.6.2 Les requêtes SQL

Pour connaître le nombre de blocs dans notre table Etudiant_2 :

```
1 SELECT blocks,bytes FROM user_segments WHERE segment_name='ETUDIANT_2';
```

BLOCKS	BYTES
768	6291456

```
7 /* Résultat de la requête après l'augmentation du nombre de blocs: */
```

BLOCKS	BYTES
1024	8388608

```
1 CREATE OR REPLACE PROCEDURE proc1 AS
2 descr varchar(50);
3 BEGIN
4 descr := '01234567890123456789012341234567' ; /*descriptif de 25 a 32*/
5 UPDATE ETUDIANT_2
6 SET descriptif=descr ;
7 end;
```

Obtenir le pourcentage de l'attribut PCT_FREE de notre table:

```
1 SELECT PCT_FREE FROM user_tables WHERE table_name='ETUDIANT_2';
```

PCT_FREE
10

3.6.3 Résultats des tests & Interprétation

Après la création de la table de base, on obtient une table de 768 blocs ayant 10% de PCT_FREE. Il faut donc augmenter la taille des tuples de plus de 10% pour déclencher l'allocation de blocs.

On calcule la nouvelle taille du champ descriptif comme suit:

$$768 * 8192 = 6291456$$

$$6291456 * 10\% = 629145$$

$$629145 / 100000 = 6.29$$

On trouve donc que chaque tuple devra augmenter sa taille de 7 octets pour agrandir la table de 10%, on ajoutera donc 7 caractères à la description de chaque étudiant grâce à la procédure citée précédemment. Comme prévu, le nombre de blocs est augmenté à 1024 après l'exécution de notre procédure. On note que si on repasse le descriptif de nos étudiants à 25, le nombre de blocs ne repasse pas à 768 mais reste à 1024. On en conclue que la clause PCT_FREE permet une certaine souplesse dans le remplissage de la table par rapport à la taille de celle-ci.

3.7 Test 7 : Étude des plans d'exécution de requêtes multi-critères en présence d'un ou plusieurs indexes, secondaires ou bitmap.

3.7.1 Ce que l'on cherche

On veut ici étudier les plans d'exécutions utilisé par Oracle dans une requête avec des opérateurs logique AND et/ou OR ayant ou non un ou plusieurs index secondaire et/ou bitmap. Ce test a pour but l'optimisation de requête.

3.7.2 Condition de l'expérience

Tout d'abord, nous utiliserons la table Etudiant_2 qui possède 100 000 tuples puis nous ferons plusieurs test. Chaque test a pour but de visualiser le plan d'exécution de nos requêtes. L'une de nos requête portant sur un AND logique et l'autre sur un OR logique, elles auront toute les deux les mêmes critères de sélection portant sur VilleEtu et le Genre.

Nous ferons varier l'utilisation des index secondaire et bitmap suivant le tableau suivant :

	INDEX		BITMAP		AND	OR
	VilleEtu	Genre	VilleEtu	Genre		
Test 1 :	x				x	x
Test 2 :		x			x	x
Test 3 :	x	x			x	x
Test 4 :			x		x	x
Test 5 :				x	x	x
Test 6 :			x	x	x	x
Test 7 :	x			x	x	x
Test 8 :	x		x		x	x
Test 9 :		x	x		x	x
Test 10 :		x		x	x	x
Test 11 :					x	x

Figure 3.8: Planification des tests

3.7.3 Les requêtes SQL

```

1 select count(*) from etudiant_2
  where VilleEtu = Bressey AND
  genre='M';
1 select count(*) from etudiant_2
  where VilleEtu = Bressey OR
  genre='M';

```

Figure 3.9: Requetes multi-critères utilisées pour afficher le plan d'exécution des indexes secondaires et/ou bitmap

Nous avons supprimé ces lignes des plans d'exécutions pour "alléger" les pages suivantes, tous les plans contenant ces deux lignes peu utiles:

1	0	SELECT STATEMENT		1	9	1 (0)	00:00:0X
2	1	SORT AGGREGATE		1	9		

3.7.4 Résultats des tests

		INDEX	BITMAP
Test 1 :	AND	INDEX RANGE SCAN sur VilleEtu	
	OR	TABLE ACCESS FULL sur la table Etudiant	
Test 2 :	AND	INDEX RANGE SCAN sur Genre	
	OR	TABLE ACCESS FULL sur la table Etudiant	
Test 3 :	AND	INDEX RANGE SCAN sur VilleEtu	
	OR	BITMAP CONVERSION FROM ROWID INDEX RANGE SCAN sur VilleEtu et Genre	
Test 4 :	AND		BITMAP CONVERSION TO ROWID BITMAP INDEX SINGLE VALUE sur Ville
	OR		TABLE ACCESS FULL
Test 5 :	AND		BITMAP CONVERSION TO ROWID BITMAP INDEX SINGLE VALUE sur Genre
	OR		TABLE ACCESS FULL
Test 6 :	AND		BITMAP AND BITMAP INDEX SINGLE VALUE sur Genre BITMAP INDEX SINGLE VALUE sur VilleEtu
	OR		BITMAP OR BITMAP INDEX SINGLE VALUE sur Genre BITMAP INDEX SINGLE VALUE sur VilleEtu
Test 7 :	AND	INDEX RANGE SCAN sur VilleEtu	
	OR	INDEX RANGE SCAN sur VilleEtu	BITMAP OR BITMAP INDEX SINGLE VALUE sur Genre
Test 8 :	AND	INDEX RANGE SCAN sur VilleEtu	
	OR	TABLE ACCESS FULL sur la table Etudiant	
Test 9 :	AND	INDEX RANGE SCAN sur Genre	BITMAP OR BITMAP INDEX SINGLE VALUE sur VilleEtu
	OR	INDEX RANGE SCAN sur Genre	
Test 10 :	AND	INDEX RANGE SCAN sur Genre	
	OR	TABLE ACCESS FULL sur la table Etudiant	
Test 11 :	AND		BITMAP INDEX SINGLE VALUE sur Genre
	OR	TABLE ACCESS FULL sur la table Etudiant	

Figure 3.10: Tableau des plans d'exécutions des différents tests

3.7.5 Interprétation des résultats

Les requêtes portent ici sur la ville de Bressey qui représente environ 39% des tuples de la table et le genre M (masculin) est majoritaire dans la table etudiant_2 à hauteur de 55% des tuples. On peut donc s'attendre à énormément de lignes sélectionnées.

On peut remarquer que pour tout les cas où l'on utilise le AND logique et que l'on a à la fois un index secondaire et un index bitmap on a systématiquement l'utilisation d'un index secondaire sauf pour le cas du test 9 car l'index bitmap sur la ville est nécessaire.

De plus, nous pouvons remarquer que l'index secondaire est toujours prioritaire sur l'index bitmap dans le cas où l'on aurait créé un index secondaire puis un index bitmap sur un même attribut.

Nous pouvons aussi remarquer que certaines requêtes sont similaires. Nous pouvons donc lier différents tests (ce qui nous permettrait de ne pas faire de requête inutiles à l'avenir dans ce genre de cas) :

Pour les AND : Test 1 = 3 = 7 = 8
Pour les OR : Test 1 = 2 = 9 = 10 = 11

3.8 Test 8 : Identification des situations dans lesquelles chaque type d'algorithme de jointure est utilisé.

3.8.1 Ce que l'on cherche

Pour ce test, nous cherchons à mettre en évidence à quel moment Oracle choisi d'utiliser un algorithme de jointure et pourquoi il le fait. Pour les algorithmes de jointure cartésien, hashage et sort-merge nous utilisons 2 tables étudiant, `etudiant_1` et `etudiant_2` n'ayant aucun index et ayant une primary key sur leurs numéro étudiant.

Pour les algorithmes de key-lookup nous organisons les tables comme cela :

`etudiant_1` = primary key `noEtu` + Organization index

`etudiant_2` = aucune primary key + index secondaire sur `noEtu/ville`

3.8.2 Les requêtes SQL & Résultats des tests

Jointure par produit cartésien

```
1 SELECT COUNT(*) FROM ETUDIANT_1 E1, ETUDIANT_2 E2 WHERE E1.gendre!=E2.gendre
   AND E1.descriptif like '%' AND E2.descriptif like '%';
```

	Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0		SELECT STATEMENT		1	2010	117K (2)	00:23:33
1		SORT AGGREGATE		1	2010		
2		NESTED LOOPS		49M	93G	117K (2)	00:23:33
* 3		TABLE ACCESS FULL	ETUDIANT_2	9942	9757K	22 (0)	00:00:01
* 4		TABLE ACCESS FULL	ETUDIANT_1	5000	4907K	12 (0)	00:00:01

3 - filter("E2"."DESCRIPTIF" IS NOT NULL AND "E2"."DESCRIPTIF" LIKE '%')

4 - filter("E1"."DESCRIPTIF" IS NOT NULL AND "E1"."DESCRIPTIF" LIKE '%'
AND "E1"."GENRE"<>"E2"."GENRE")

Jointure par hashage

```
1 SELECT * FROM ETUDIANT_1 E1, ETUDIANT_2 E2 WHERE E1.VilleEtu=E2.VilleEtu
   AND E1.VilleEtu='Paris';
```

	Id	Operation	Name	Rows	Bytes
0		SELECT STATEMENT		1	2130
* 1		HASH JOIN		1	2130
* 2		TABLE ACCESS FULL	ETUDIANT_2	1	1065
* 3		TABLE ACCESS FULL	ETUDIANT_1	811	843K

1 - access("E1"."VILLEETU"="E2"."VILLEETU")

2 - filter("E2"."VILLEETU"='Paris')

3 - filter("E1"."VILLEETU"='Paris')

Jointure par sort-merge

```
1 SELECT * FROM ETUDIANT_1 E1, ETUDIANT_2 E2 WHERE E1.noEtu>E2.noEtu AND
2 E2.descriptif like '%';
```

	Id	Operation	Name	Rows	Bytes	Cost (%CPU)	Time
0		SELECT STATEMENT		99M	197G	117K (2)	00:23:27
1		MERGE JOIN CARTESIAN		99M	197G	117K (2)	00:23:27
2		TABLE ACCESS FULL	ETUDIANT_2	9942	10M	22 (0)	00:00:01
3		BUFFER SORT		10000	10M	117K (2)	00:23:27
4		TABLE ACCESS FULL	ETUDIANT_1	10000	10M	12 (0)	00:00:01

Jointure par key-lookup - Index Primaire

```
1 SELECT * FROM ETUDIANT_1 E, ETUDIANT_2 V WHERE E.noEtu=V.noEtu;
```

	Id	Operation	Name	Rows	Bytes	Cost(%CPU)	Time
0		SELECT STATEMENT		9614	19M	13 (0)	00:00:01
1		NESTED LOOPS					
2		NESTED LOOPS		9614	19M	13 (0)	00:00:01
3		TABLE ACCESS FULL	ETUDIANT_1	10000	10M	13 (0)	00:00:01
* 4		INDEX RANGE SCAN	INOETU	1		0 (0)	00:00:01
5		TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	1	1065	0 (0)	00:00:01

4 - access("E"."NOETU"="V"."NOETU")

Jointure par key-lookup - Index Secondaire

```
1 SELECT * FROM ETUDIANT_1 E1, ETUDIANT_2 E2 WHERE E1.villeEtu=E2.villeEtu
AND E1.villeEtu like '%';
```

	Id	Operation	Name	Rows	Bytes	Cost(%CPU)	Time
0		SELECT STATEMENT		10M	21G	66 (81)	00:00:01
1		NESTED LOOPS					
2		NESTED LOOPS		10M	21G	66 (81)	00:00:01
* 3		TABLE ACCESS FULL	ETUDIANT_1	10000	10M	13 (0)	00:00:01
* 4		INDEX RANGE SCAN	IVILLE	53		0 (0)	00:00:01
5		TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	1068	1110K	0 (0)	00:00:01

3 - filter("E"."VILLEETU" LIKE '%' AND "E"."VILLEETU" IS NOT NULL)
4 - access("E"."VILLEETU"="V"."VILLEETU")
filter("V"."VILLEETU" LIKE '%' AND "V"."VILLEETU" IS NOT NULL)

3.8.3 Interprétation des résultats

Nous sommes parvenus à trouver des requêtes permettant à Oracle d'utiliser tous les types d'algorithmes de jointure disponibles.

On remarque que:

- Le produit cartésien est utilisé quand les filtres ne sont pas très restrictifs. En effet, au delà des deux dernières clauses permettant de forcer la lecture des tuples, on ne cherche qu'à joindre les tuples ayant un genre différent. On effectue alors une jointure que l'on peut considérer comme naïve et la NESTED_LOOP est donc parfaitement adaptée.
- Pour la jointure par hashage, on comprends ici que Oracle doit identifier des correspondances entre des attributs ayant peu de valeurs différentes dans les deux tables. Après le hashage l'accès aux tuples sera plus rapide.
- Pour la jointure sort-merge, on comprend qu'Oracle s'attend à traiter beaucoup de données différentes et devra les comparer. En effet dans la requête, on demande des numéros d'étudiants supérieurs à ceux de l'autre table. Trier les données permet donc un gain de temps car on peut déterminer quand on aura plus de correspondances entre les tuples pendant le déroulement du balayage.
- Pour le key-lookup, un index est nécessaire. Nous avons donc essayé ici avec un index primaire et un secondaire. On remarque que le fonctionnement est similaire pour les deux indexes. L'index primaire étant tout de même plus rapide car on n'utilise pas de pointeurs. Cette jointure est comparable à la jointure par produit cartésien car elle fonctionne de la même manière à l'exception que key-lookup exploite l'index. Le choix de key-lookup est judicieux ici car on cherche à faire correspondre des tuples ayant des attributs égaux contrairement à la jointure par produit cartésien (qui avait une inégalité), l'exploitation d'un index est fortement utile pour repérer les correspondances.

Partie 4

Conclusion

La réalisation de ces séances de TP et de ce rapport nous ont permis de comprendre le fonctionnement interne d'un SGBD lors de la résolution des requêtes, mais aussi d'identifier les approches de modélisation des bases de données ORACLE de façon optimisée. En effet l'utilisation des indexes et des clusters nous semble maintenant indispensable dans la modélisation d'une base de données performante. Nous sommes convaincus que ce travail nous à été bénéfique et qu'il nous sera grandement utile par la suite.

Annexe A

Construction des tables

```
1 DROP TABLE Etudiant_1;
2 DROP TABLE Ville_1;
3 DROP TABLE Genre;
4 DROP TABLE Stat_Marital;
5 DROP INDEX IVILLE_1;
6
7
8 CREATE TABLE Ville_1
9 (
10     nomVille VARCHAR(50),
11     borneMin number(2),
12     borneMax number(2),
13     PRIMARY KEY(nomVille)
14 );
15
16
17
18 CREATE TABLE Genre
19 (
20     type_genre CHAR(1),
21     borneMin number(2),
22     borneMax number(2),
23     PRIMARY KEY(type_genre)
24 );
25
26
27
28 CREATE TABLE Stat_Marital
29 (
30     Statut_Marital CHAR(1),
31     borneMin number(2),
32     borneMax number(2),
33     PRIMARY KEY(Statut_Marital)
34 );
35
36
37
38
```

```

39 CREATE TABLE Etudiant_1
40 (
41     noEtu NUMBER(6,0),
42     nomEtu VARCHAR(50),
43     villeEtu VARCHAR(30),
44     statut_Marital CHAR(1),
45     genre CHAR(1),
46     descriptif VARCHAR(2000),
47
48     PRIMARY KEY (NoEtu),
49     FOREIGN KEY (statut_Marital) REFERENCES Stat_Marital(Statut_Marital),
50     FOREIGN KEY (villeEtu) REFERENCES Ville_1(nomVille),
51     FOREIGN KEY (genre) REFERENCES Genre(type_genre)
52 );
53
54 CREATE INDEX IVILLE_1 ON ETUDIANT_1(Villeetu);
55
56 /*-----*/
57 INSERT INTO Ville_1 VALUES ( 'Paris' ,1,2 );
58 INSERT INTO Ville_1 VALUES ( 'Lyon' ,2,5 );
59 INSERT INTO Ville_1 VALUES ( 'Dijon' ,5,9 );
60 INSERT INTO Ville_1 VALUES ( 'Chalon' ,9,14 );
61 INSERT INTO Ville_1 VALUES ( 'Longvic' ,14,20 );
62 INSERT INTO Ville_1 VALUES ( 'Quetigny' ,20,27 );
63 INSERT INTO Ville_1 VALUES ( 'Chenove' ,27,37 );
64 INSERT INTO Ville_1 VALUES ( 'Chevigny' ,37,60 );
65 INSERT INTO Ville_1 VALUES ( 'Bressey' ,60,99 );
66
67
68 INSERT INTO Genre VALUES ( 'M' ,0,55 );
69 INSERT INTO Genre VALUES ( 'F' ,55,99 );
70
71
72 INSERT INTO Stat_Marital VALUES ( 'C' ,0,80 );
73 INSERT INTO Stat_Marital VALUES ( 'P' ,80,90 );
74 INSERT INTO Stat_Marital VALUES ( 'M' ,90,95 );
75 INSERT INTO Stat_Marital VALUES ( 'D' ,95,98 );
76 INSERT INTO Stat_Marital VALUES ( 'V' ,98,99 );
77 /*-----*/
78
79
80
81
82
83
84
85
86
87

```



```

88 CREATE OR REPLACE PROCEDURE genereetu as
89   n_index NUMBER(5);
90   randome NUMBER;
91   ville VARCHAR(50);
92   genre VARCHAR(1);
93   stats VARCHAR(1);
94
95 BEGIN
96   FOR n_index IN 1..100000
97     LOOP
98       randome:= DBMS_RANDOM.value(1,99);
99       SELECT nomVille INTO ville FROM Ville_1 WHERE randome>=Ville_1 .
100       borneMin AND randome<Ville_1.borneMax;
101       SELECT type_genre INTO genre FROM Genre WHERE randome>=Genre .
102       borneMin AND randome<Genre.borneMax;
103       SELECT statut_Marital INTO stats FROM Stat_Marital WHERE randome>=
104       Stat_Marital.borneMin AND randome<Stat_Marital.borneMax;
105       INSERT INTO Etudiant_1 VALUES(n_index, 'Bob',ville,stats,genre, '
106       Description de l etudiant');
107     END LOOP;
108 END genereetu;
109 /
110
111 BEGIN
112 genereetu;
113 end;
114 /

```

Annexe B

Mesures

Nos mesures sont disponibles dans le tableur Excel joint avec ce rapport.

Annexe C

Plans d'exécution du test 7

Test 1:AND

1						
2		Id		Operation		Name
3						Rows
4		*	2		TABLE ACCESS BY INDEX ROWID	ETUDIANT.2
5		*	3		INDEX RANGE SCAN	IVILLE
6						Bytes
7						
8						

2 - filter ("GENRE"='M')

3 - access ("VILLEETU"='Chevigny ')

Test 1:OR

1						
2		Id		Operation		Name
3						Rows
4		*	2		TABLE ACCESS FULL	ETUDIANT.2
5						Bytes
6						

2 - filter ("VILLEETU"='Chevigny ' OR "GENRE"='M')

Test 2:AND

1						
2		Id		Operation		Name
3						Rows
4		*	2		TABLE ACCESS BY INDEX ROWID	ETUDIANT.2
5		*	3		INDEX RANGE SCAN	IGENRE
6						Bytes
7						
8						

2 - filter ("VILLEETU"='Chevigny ')

3 - access ("GENRE"='M')

Test 2:OR

1						
2		Id		Operation		Name
3						Rows
4		*	2		TABLE ACCESS FULL	ETUDIANT.2
5						Bytes
6						

2 - filter ("VILLEETU"='Chevigny ' OR "GENRE"='M')

Test 3:AND

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	16278	317K
* 3	INDEX RANGE SCAN	IVILLE	20600	
2 - filter ("GENRE"='M')				
3 - access ("VILLEETU"='Chevigny ')				

Test 3:OR

Id	Operation	Name	Rows	Bytes
2	BITMAP CONVERSION COUNT		53405	1043K
3	BITMAP OR			
4	BITMAP CONVERSION FROM ROWIDS			
* 5	INDEX RANGE SCAN	IVILLE		
6	BITMAP CONVERSION FROM ROWIDS			
* 7	INDEX RANGE SCAN	IGENRE		
5 - access ("VILLEETU"='Chevigny ')				
7 - access ("GENRE"='M')				

Test 4:AND

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	16741	326K
3	BITMAP CONVERSION TO ROWIDS			
* 4	BITMAP INDEX SINGLE VALUE	BIT_VILLE		
2 - filter ("GENRE"='M')				
4 - access ("VILLEETU"='Chevigny ')				

Test 4:OR

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS FULL	ETUDIANT_2	56290	1099K
2 - filter ("VILLEETU"='Chevigny ' OR "GENRE"='M')				

Test 5:AND

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	17655	344K
3	BITMAP CONVERSION TO ROWIDS			
* 4	BITMAP INDEX SINGLE VALUE	BIT_GENRE		
2 - filter ("VILLEETU"='Chevigny ')				
4 - access ("GENRE"='M')				

Test 5:OR

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS FULL	ETUDIANT_2	55803	1089K
2 - filter ("VILLEETU"='Chevigny ' OR "GENRE"='M')				

Test 6:AND

Id	Operation	Name	Rows	Bytes
2	BITMAP CONVERSION COUNT		23390	456K
3	BITMAP AND			
* 4	BITMAP INDEX SINGLE VALUE	BIT_GENRE		
* 5	BITMAP INDEX SINGLE VALUE	BIT_VILLE		
4 - access ("GENRE"='M')				
5 - access ("VILLEETU"='Chevigny ')				

Test 6:OR

Id	Operation	Name	Rows	Bytes
2	BITMAP CONVERSION COUNT		76913	1502K
3	BITMAP OR			
* 4	BITMAP INDEX SINGLE VALUE	BIT_VILLE		
* 5	BITMAP INDEX SINGLE VALUE	BIT_GENRE		
4 - access ("VILLEETU"='Chevigny ')				
5 - access ("GENRE"='M')				

Test 7:AND

	Id	Operation	Name	Rows	Bytes
	* 2	TABLE ACCESS BY INDEX ROWID	ETUDIANT.2	16195	316K
	* 3	INDEX RANGE SCAN	IVILLE	20790	
2	filter ("GENRE"='M')				
3	access ("VILLEETU"='Chevigny ')				

Test 7:OR

	Id	Operation	Name	Rows	Bytes
	2	BITMAP CONVERSION COUNT		52633	1027K
	3	BITMAP OR			
	4	BITMAP CONVERSION FROM ROWIDS			
	* 5	INDEX RANGE SCAN	IVILLE		
	* 6	BITMAP INDEX SINGLE VALUE	BIT.GENRE		
5	access ("VILLEETU"='Chevigny ')				
6	access ("GENRE"='M')				

Test 8:AND

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	22666	442K
* 3	INDEX RANGE SCAN	IVILLE	28780	
2 - filter ("GENRE"='M')				
3 - access ("VILLEETU"='Chevigny ')				

Test 8:OR

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS FULL	ETUDIANT_2	75192	1468K
2 - filter ("VILLEETU"='Chevigny ' OR "GENRE"='M')				

Test 9:AND

Id	Operation	Name	Rows	Bytes
2	BITMAP CONVERSION COUNT		57359	1120K
3	BITMAP OR			
* 4	BITMAP INDEX SINGLE VALUE	BIT_VILLE		
5	BITMAP CONVERSION FROM ROWIDS			
* 6	INDEX RANGE SCAN	IGENRE		
4 - access ("VILLEETU"='Chevigny ')				
6 - access ("GENRE"='M')				

Test 9:OR

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	17465	341K
* 3	INDEX RANGE SCAN	IGENRE	52514	
2 - filter ("VILLEETU"='Chevigny ')				
3 - access ("GENRE"='M')				

Test 10:AND

Id	Operation	Name	Rows	Bytes
* 2	TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	17275	337K
* 3	INDEX RANGE SCAN	IGENRE	51695	
2 - filter ("VILLEETU"='Chevigny ')				
3 - access ("GENRE"='M')				

Test 10:OR

	Id	Operation	Name	Rows	Bytes
	* 2	TABLE ACCESS FULL	ETUDIANT_2	56492	1103K
	2 - filter ("VILLEETU"='Chevigny ' OR "GENRE"='M')				

Test 11:AND

	Id	Operation	Name	Rows	Bytes
	* 2	TABLE ACCESS BY INDEX ROWID	ETUDIANT_2	21419	418K
	3	BITMAP CONVERSION TO ROWIDS			
	* 4	BITMAP INDEX SINGLE VALUE	BIT_GENRE		
	2 - filter ("VILLEETU"='Chevigny ')				
	4 - access ("GENRE"='M')				

Test 11:OR

	Id	Operation	Name	Rows	Bytes
	* 2	TABLE ACCESS FULL	ETUDIANT_2	68911	1345K
	2 - filter ("VILLEETU"='Chevigny ' OR "GENRE"='M')				